

Momentum：把单步梯度变成时间方向

第二讲：指数平均、噪声过滤与惯性

上一讲我们把 SGD 看成带噪声的梯度下降。本讲只加一个新变量：动量。它的作用不是改变参数空间的坐标尺度，而是在时间上整理梯度信号。

本讲要回答

- Momentum 为什么是梯度的指数移动平均？
- 它如何降低 mini-batch 梯度噪声？
- 为什么它能减弱狭长谷里的来回震荡？
- 它和 Adam、Muon 的关系在哪里？

本讲先不做

- 不展开 Adam 的二阶矩缩放。
- 不证明 Muon 的正交化性质。
- 先把“时间平均”这件事讲透。

读法建议：把 μ 当成“记忆长度”的旋钮，把 η 当成“走多远”的旋钮。它们会一起决定训练的稳定性。

SGD 的问题不是只有随机，它还太健忘

本讲统一用 F 表示当前正在优化或分析的目标。训练集上通常就是经验风险：

$$F = \hat{L}_N$$

上一讲我们把 mini-batch 梯度写成：

$$g_t = \nabla F(\theta_t) + \xi_t, \quad E[\xi_t | \theta_t] = 0$$

SGD 每一步只用当前这个 g_t ：

$$\theta_{t+1} = \theta_t - \eta_t g_t$$

如果方向连续同向

单步梯度没有利用“很多步都在说同一件事”这个证据。

如果方向来回变号

单步梯度会直接跟着震荡，尤其是在大曲率方向。

Momentum 的想法很朴素：不要只听当前 mini-batch，要听最近一段时间的平均意见。

动量变量 m_t 是梯度的时间平均

本讲采用归一化的指数移动平均写法。初始动量取 0，并定义：

$$m_t = \mu m_{t-1} + (1 - \mu) g_t$$

$$\theta_{t+1} = \theta_t - \eta_t m_t$$

符号说明

- g_t ：第 t 步的 mini-batch 梯度。
- m_t ：到第 t 步为止的动量信号。
- μ ：动量系数，满足 $0 \leq \mu < 1$ 。
- η_t ：学习率，控制沿 m_t 走多远。
- θ_t ：第 t 步更新前的参数。
- F ：当前分析目标，训练时通常为 $\hat{L}_N$ 。

和代码里的写法有什么区别？


很多 SGD momentum 实现写成 $v_t = \mu v_{t-1} + g_t$ 。这和这里的 m_t 只差一个大约为 $1 - \mu$ 的尺度，通常可以吸收到学习率里。本讲用 m_t 是为了让“平均”这件事更清楚。

μ 决定我们记住多远的过去

把 m_t 的递推展开，可以看到它不是玄学变量，而是一个加权平均：

$$m_t = \left(1 - \mu\right) \sum_{k=0}^t \mu^{t-k} g_k$$

离现在越近的梯度权重越大，越久以前的梯度权重按 μ 的幂次衰减。



$\mu = 0$

$m_t = g_t$ ，退化回普通 SGD。

$\mu = 0.9$

有效记忆长度约为 10 步。

$\mu = 0.99$

有效记忆长度约为 100 步，但反应更慢。

一个很实用的近似：有效记忆长度约为 $1 / (1 - \mu)$ 。 μ 越接近 1，平均越平滑，滞后也越明显。

Momentum 为什么能让梯度更稳？

假设在一小段时间内真实梯度变化不大，并且 mini-batch 噪声近似独立：

$$g_t = h + \xi_t, \quad h = \nabla F(\theta), \quad \text{Cov}(\xi_t) \approx \frac{\Sigma}{B}$$

那么动量平均后的噪声协方差近似为：

$$\text{Cov}(m_t) \approx \frac{1 - \mu}{1 + \mu B} \Sigma$$

例子： $\mu = 0.9$

方差约乘以 $1/19$ ，标准差约乘以 0.23 。
也就是说，动量信号比单步梯度平滑很多。

但有代价

如果真实梯度方向突然改变， m_t 还带着旧方向的记忆，会产生滞后甚至过冲。

这正是 Momentum 的核心取舍：用反应速度换取噪声过滤。

从信号处理角度看，Momentum 是一个低通滤波器：保留慢变化的方向，削弱高频抖动。

为什么训练刚开始时动量会偏小？

因为初始动量取 0，所以最开始的平均里混入了“过去全是 0”的假设。如果真实梯度近似不变，记为 h ，那么：

$$E[m_t] \approx (1 - \mu^{t+1})h$$

因此可以定义一个偏差修正后的动量：

$$\hat{m}_t = \frac{m_t}{1 - \mu^{t+1}}$$

SGD Momentum

经典实现通常不显式做偏差修正，而是通过 warmup 和学习率安排缓和开头阶段。

Adam

Adam 会对一阶矩和二阶矩都做偏差修正。这就是下一讲会自然出现的公式。

实现提醒

如果使用偏差修正，就先把 m_t 除以 $1 - \mu^{t+1}$ ，再用于参数更新。经典 SGD Momentum 通常不显式写这一步。

偏差修正回答的是“开头几步平均值偏小”的问题，不是 Momentum 的主要思想。主要思想仍然是时间平均。

Momentum 把一阶递推变成二阶递推

看一维二次目标。这里没有随机噪声，只观察确定性动力学：

$$F(\theta) = \frac{1}{2}\lambda\theta^2, \quad g_t = \lambda\theta_t$$

代入归一化 Momentum：

$$m_t = \mu m_{t-1} + (1 - \mu)\lambda\theta_t, \quad \theta_{t+1} = \theta_t - \eta m_t$$

消去 m_t 后，得到关于 θ 的二阶递推：

$$\theta_{t+1} = (1 + \mu - \eta(1 - \mu)\lambda)\theta_t - \mu\theta_{t-1}$$

对应的特征方程是：

$$r^2 - (1 + \mu - \eta(1 - \mu)\lambda)r + \mu = 0$$

SGD 像一阶系统，只看当前位置的斜率。Momentum 像带惯性的二阶系统，会同时记住当前位置和上一段运动趋势。

为什么 Momentum 能减弱来回震荡？

在病态二次型里，不同方向的曲率差很多。陡峭方向的梯度容易来回变号，平坦方向的梯度更容易连续同向。



陡峭方向

梯度符号经常交替。指数平均会把正负波动互相抵消，所以震荡被削弱。

平坦方向

梯度长期同向。指数平均会累积这个方向，让有效更新更稳定。

但是

Momentum 仍然只有一个全局学习率。它不能真正把每个方向的曲率都缩放到合适尺度。

这也是为什么 Momentum 很常用，但它不是自适应优化器。它解决的是“时间上的抖动”，不是“坐标上的尺度不一致”。

Nesterov Momentum：先看一眼将要到达的位置

普通 Momentum 用当前位置 θ_t 上的梯度更新 m_t 。Nesterov 的想法是：既然动量会把我们推向前方，那就先在前方位置看一眼梯度。

$$\theta_t^{\text{look}} = \theta_t - \eta_t \mu m_{t-1}$$

$$g_t = \nabla F(\theta_t^{\text{look}}), \quad m_t = \mu m_{t-1} + (1 - \mu) g_t$$

$$\theta_{t+1} = \theta_t - \eta_t m_t$$

直觉

如果前方已经开始偏离好方向，Nesterov 会更早看到这个偏离，从而更早修正。

不要过度神化

在深度学习实践里，Nesterov 常常有帮助，但它仍然属于时间平均家族，不是坐标自适应方法。

本讲把普通 Momentum 作为主线。Nesterov 是同一思想的“前瞻版”。

Momentum 没有改变参数空间的度量

Momentum 的更新仍然是：

$$\theta_{t+1} = \theta_t - \eta_t m_t$$

它改变了 m_t 的时间质量，却没有给不同坐标不同缩放。若要改变参数空间里的尺度，通常需要一个预条件器：

$$\theta_{t+1} = \theta_t - \eta_t P_t m_t$$

方法家族	主要改造	解决什么
Momentum	m_t 是梯度的时间平均	降低单步噪声，减弱震荡
AdaGrad / RMSProp / Adam	P_t 是坐标级缩放	处理不同坐标的梯度尺度差异
Shampoo / SOAP / Muon	P_t 或更新方向利用矩阵结构	处理矩阵参数的几何结构

所以从 SGD 到现代优化器，有两条线同时发展：时间上更稳，空间上更会缩放。

矩阵参数上的 Momentum 是 Muon 的入口

对于线性层权重矩阵：


$$W_t \in \mathbb{R}^{m \times n}$$

mini-batch 梯度也是一个矩阵，记作 G_t 。矩阵版 Momentum 写成：

$$M_t = \mu M_{t-1} + (1 - \mu) G_t$$

$$W_{t+1} = W_t - \eta_t M_t$$

Muon 的关键转弯是：不直接用 M_t 更新，而是先把 M_t 当成矩阵方向，再做几何整理，得到 U_t 。



$$U_t \approx \text{Orth}(M_t), \quad W_{t+1} = W_t - \eta_t U_t$$

这不是 Muon 的完整定义，只是入口：Muon 不是抛弃 Momentum，而是在 Momentum 之后再做矩阵几何处理。

本讲你应该带走的四句话

1. Momentum 把单步梯度 g_t 变成时间平均 m_t 。
2. μ 越大，噪声越小，但方向变化时滞后越强。
3. 在狭长谷里，Momentum 会削弱陡峭方向的震荡，增强平坦方向的持续运动。
4. Momentum 解决的是时间问题；Adam 和 Muon 还要继续解决空间几何问题。

$$m_t = \mu m_{t-1} + (1 - \mu) g_t, \quad \theta_{t+1} = \theta_t - \eta m_t$$

课后自检

- 能否解释 $\mu = 0.9$ 为什么约等于记住 10 步？
- 能否说清 Momentum 降低的是哪一种误差？
- 能否区分 Momentum 和 Adam 的核心差别？

下一讲预告

我们会进入 AdaGrad、RMSProp 和 Adam：不再只平均梯度本身，还要估计每个坐标的梯度尺度，从而构造坐标级自适应步长。

如果 lecture01 是“SGD 是什么”，lecture02 就是“为什么要记住过去”。下一讲会回答“为什么不同坐标不该用同一个尺子”。