

Adam：为什么不同坐标不该用同一把尺子

第三讲：自适应缩放、二阶矩与 AdamW

Momentum 在时间上平均梯度，但仍然用一个全局学习率。Adam 的核心转弯是：每个坐标都维护自己的尺度估计，让噪声大或梯度大的坐标走得更谨慎。

本讲要回答

- 为什么只靠 Momentum 还不够？
- AdaGrad、RMSProp、Adam 分别改了什么？
- Adam 的一阶矩、二阶矩和偏差修正是什么？
- AdamW 为什么要把 weight decay 解耦？

本讲先不做

- 不讨论矩阵正交化。
- 不把 Adam 的所有收敛反例展开。
- 不直接给 Muon 配方，先把坐标自适应讲清楚。

这组讲义会固定符号： F 表示当前训练目标，训练时通常 $F = \hat{L}_N$ ； g_t 是 mini-batch 梯度， m_t 是一阶动量。

Momentum 只在时间上平均，没有改坐标尺度

上一讲的 Momentum 更新可以写成：

$$m_t = \mu m_{t-1} + (1 - \mu)g_t, \quad \theta_{t+1} = \theta_t - \eta_t m_t$$

它让方向更平滑，但 η_t 仍然是一个标量。也就是说，每个坐标都被同一个学习率缩放。

时间问题

单步梯度太吵，Momentum 用过去的平均来稳定方向。

坐标问题

不同坐标的梯度尺度可能差很多，一个 η 很难同时适合所有坐标。

自适应优化器的入口就是把标量步长改成坐标级步长：

$$\theta_{t+1} = \theta_t - \eta_t P_t m_t$$


P_t 是一个对角缩放矩阵时，就是坐标级自适应； P_t 变成矩阵或张量结构时，就通往 Shampoo、SOAP 和 Muon 的邻近地带。

把每个坐标的步长分开

令第 j 个坐标的一阶动量为 $m_{t,j}$ 。如果给每个坐标一个尺度 $s_{t,j}$ ，更新就变成：

$$\theta_{t+1,j} = \theta_{t,j} - \eta_t \cdot m_{t,j} / (s_{t,j} + \epsilon)$$

这里 $s_{t,j}$ 通常来自历史梯度平方。梯度平方大，说明这个坐标经常有大梯度或高噪声，于是步长会被压小。



Adam 的“聪明”不是知道哪个方向一定更好，而是用历史数据估计每个坐标的天然单位。

AdaGrad：把所有过去的平方梯度都累加

AdaGrad 的尺度来自累计平方梯度：

$$v_t = v_{t-1} + g_t \odot g_t$$

$$\theta_{t+1} = \theta_t - \eta \cdot g_t / (\sqrt{v_t} + \varepsilon)$$

优点

出现频繁、大梯度的坐标会自动变小步长；
稀疏特征场景很有吸引力。

问题

v_t 只增不减，训练后期步长可能衰减得太厉害。

AdaGrad 给了一个重要思想：学习率不必全局共享，可以从梯度历史里估计。

如果 Momentum 是“过去方向的平均”，AdaGrad 就是“过去尺度的记账”。

RMSProp: 只记最近一段时间的平方梯度

RMSProp 把 AdaGrad 的累计和改成指数移动平均:

$$v_t = \rho v_{t-1} + (1 - \rho)(g_t \odot g_t)$$

$$\theta_{t+1} = \theta_t - \eta \cdot g_t / (\sqrt{v_t} + \epsilon)$$

这样 v_t 不再只增不减，而是主要反映最近的梯度尺度。

ρ 接近 0

尺度估计反应快，但更吵。

ρ 接近 1

尺度估计更平滑，但变化慢。

RMSProp 还没有一阶动量 m_t 的完整偏差修正，但它已经把“二阶矩估计”这条线打开了。

RMSProp 可以理解为：用最近的均方梯度估计每个坐标的单位。

Adam = Momentum + RMSProp + 偏差修正

Adam 同时维护一阶矩和二阶矩：

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (g_t \odot g_t)$$

由于 m_t 和 v_t 初始为 0，前几步会偏小，因此 Adam 做偏差修正：

$$\hat{m}_t = m_t / (1 - \beta_1^{t+1}), \quad \hat{v}_t = v_t / (1 - \beta_2^{t+1})$$

$$\theta_{t+1} = \theta_t - \eta \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \varepsilon)$$

一阶矩给方向，二阶矩给坐标尺度。Adam 的核心就是这两个估计的组合。

为什么除以 $\sqrt{\hat{v}_t}$ 有用？

如果某个坐标的梯度长期很大，那么 $\hat{v}_{t,j}$ 会大，这个坐标的有效步长会变小：

$$\text{effective step}_j \approx \eta / (\sqrt{\hat{v}_{t,j}} + \varepsilon)$$

方向

$\hat{m}_t$ 决定朝哪里走。

单位

$\sqrt{\hat{v}_t}$ 决定每个坐标的自然尺度。

稳定

ε 防止除以太小的数。

从这个角度看，Adam 并不只是“Momentum 更复杂版”。它改变了参数空间里的度量：同样大小的 $\hat{m}$ ，在不同坐标上会产生不同大小的参数更新。

Adam 对“坐标轴”很敏感：它假设逐坐标缩放是有意义的。这正是它和矩阵几何方法的分水岭。

AdamW：不要把 weight decay 混进自适应梯度

如果把 L2 正则直接加进梯度，Adam 会把 θ 也放进自适应分母里，导致 weight decay 和坐标缩放纠缠。

AdamW 的做法是把权重衰减从梯度更新里解耦：

$$\theta_{t+1} = (1 - \eta\lambda)\theta_t - \eta \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \varepsilon)$$

Adam

梯度项和正则项可能一起被自适应分母缩放。

AdamW

先按比例收缩权重，再做自适应梯度更新。
含义更清楚，也更常用。

后面讲 Muon 实践时也会遇到同一件事：weight decay 最好作为独立的参数收缩来理解。

Adam 仍然只看坐标，不理解矩阵结构

Adam 的预条件器是对角的：

$$P_t = \text{diag}(1 / (\sqrt{\hat{v}_t} + \epsilon))$$

这意味着它能区分不同坐标，却不能直接表达“行空间”和“列空间”的耦合关系。

问题	Adam 的回答	还缺什么
单步梯度太吵	一阶矩 m_t	已经部分解决
坐标尺度不同	二阶矩 v_t	已经部分解决
矩阵方向低秩或病态	逐坐标缩放	缺少矩阵级几何处理

这就是 lecture04 的入口：如果参数天然就是矩阵，是否应该用矩阵方式缩放梯度？

本讲你应该带走的四句话

1. AdaGrad 证明了“每个坐标一个学习率”是合理的。
2. RMSProp 把历史平方梯度改成近期平均，避免步长只降不升。
3. Adam 用一阶矩给方向，用二阶矩给坐标尺度。
4. AdamW 把 weight decay 从自适应梯度更新里解耦出来。

$$\text{Adam: direction} = \hat{m}_t, \text{ scale} = 1 / (\sqrt{\hat{v}_t} + \epsilon)$$

课后自检

- 能否说清 m_t 和 v_t 分别估计什么？
- 能否解释 AdamW 为什么不是小修小补？

下一讲预告

我们会把对角缩放升级成矩阵缩放：
Shampoo、SOAP、极分解，以及它们怎样把路铺到 Muon。

lecture02 解决时间平均，lecture03 解决坐标尺度。接下来开始进入矩阵几何。