

矩阵几何：从 Adam 走向 Muon 的桥

第四讲：预条件、Shampoo/SOAP 与极分解

Adam 把每个坐标单独缩放，但神经网络里的核心权重往往是矩阵。矩阵有行空间、列空间和奇异值结构；一旦承认这一点，Muon 的正交化更新就不再突兀。

本讲要回答

- 矩阵梯度为什么不只是长向量？
- Shampoo 怎样做左右预条件？
- 为什么“无累积 Shampoo”会出现 UV^T ？
- SOAP 和 Muon 分别继承了哪条思想？

本讲先不做

- 不深入证明 Shampoo regret bound。
- 不讨论所有二阶优化细节。
- 不讲 Muon 的完整实现，留到 lecture05。

这组讲义会固定符号： F 表示当前训练目标，训练时通常 $F = \hat{L}_N$ ； g_t 是 mini-batch 梯度， m_t 是一阶动量。

线性层权重不是普通坐标集合

考虑一个线性层权重：

$$W \in \mathbb{R}^{m \times n}, G_t = \nabla_W F(W_t)$$

如果把 W 摊平成向量，Adam 只会给每个元素一个缩放。但矩阵还有两个天然方向：

行空间

对应输出通道或神经元之间的组合。

列空间

对应输入特征或前一层表示之间的组合。

矩阵预条件的基本形状是：

$$W_{t+1} = W_t - \eta \cdot P_{L,t} G_t P_{R,t}$$

左乘改变输出空间尺度，右乘改变输入空间尺度。这是对角 Adam 做不到的。

预条件就是先换一把尺子再下降

普通梯度下降默认每个方向的单位长度一样：

$$\Delta W = -\eta G$$

预条件下降则先用 P 改变方向和尺度：

$$\Delta W = -\eta P(G)$$

对角预条件

每个元素单独缩放，
Adam 属于这一类。

矩阵预条件

按行空间和列空间缩放，
Shampoo 属于这一类。

正交化更新

把奇异值压平，Muon 属于这一类。

这三者不是互相排斥，而是越来越重视参数的结构。

从“坐标”到“矩阵”的变化，是理解 Muon 的关键台阶。

Shampoo：分别估计左右两侧的梯度尺度

对矩阵梯度 G_t ，Shampoo 维护两个累积矩阵：

$$L_t = \varepsilon I + \sum_{k \leq t} G_k G_k^T, \quad R_t = \varepsilon I + \sum_{k \leq t} G_k^T G_k$$

更新方向使用左右逆四次根：

$$U_t = L_t^{-1/4} G_t R_t^{-1/4}$$

为什么是两侧？

$G G^T$ 捕捉行空间尺度， $G^T G$ 捕捉列空间尺度。

为什么贵？

需要矩阵累积和矩阵逆根，通信与计算都比 Adam 重。

Shampoo 是重要桥梁：它说明“矩阵级缩放”可以比逐坐标缩放更贴近层结构。

去掉累积后，Shampoo 会露出 UV^T

假设只看当前梯度 G ，并令它的奇异值分解为：

$$G = U S V^T$$

如果把 Shampoo 的累积矩阵粗略替换成当前 G 的二阶矩：

$$(GG^T)^{-1/4} G (G^T G)^{-1/4} = U V^T$$

这个 $U V^T$ 就是 G 的极分解中的正交方向，也可以理解成把 G 的奇异值全部压成 1。

保留什么

保留左奇异向量 U 和右奇异向量 V ，也就是矩阵方向。

丢掉什么

丢掉奇异值 S 的大小差异，也就是把谱压平。


Muon 的核心更新正是这个方向：把动量矩阵 M 的奇异值压平，使用 $U V^T$ 作为更新方向。

Orth(G) 是离 G 最近的半正交矩阵

当 $G = U S V^T$ 时，定义：

$$\text{Orth}(G) = U V^T$$

若 G 是高矩阵或宽矩阵， $U V^T$ 是半正交的：行或列尽量互相正交。



正交化不是把矩阵元素归一化，而是把矩阵的奇异值谱压平。

Orth(G) 也是谱范数球里的最陡方向

如果用谱范数限制一次矩阵更新的大小：

$$\|\Delta W\|_2 \leq \eta$$

那么使一阶下降量最大的方向满足：

$$\arg \max_{\|U\|_2 \leq 1} \langle G, U \rangle = \text{Orth}(G)$$

这里 $\langle G, U \rangle = \text{trace}(G^T U)$ 。所以 $\text{Orth}(G)$ 可以被看成“谱范数度量下的最陡下降方向”。

欧氏度量

最陡方向就是 G 本身。

谱范数度量

最陡方向变成 $\text{Orth}(G)$ 。

这给 Muon 一个干净的数学解释：它不是随便改梯度，而是在换一种矩阵范数下做下降。

SVD 好理解，但训练时太慢

如果每一步都对每个权重矩阵做 SVD:

$$M = U S V^T, \text{ update} = U V^T$$

数学上很清楚，但在大模型训练里代价太高，也不够适合 GPU 上的高吞吐矩阵乘。

SVD

精确、解释简单，但每层每步做会很贵。

Newton-Schulz


只用矩阵乘法近似 $\text{Orth}(M)$ ，更适合现代 GPU。

Muon 选择的道路是：不用精确 SVD，而用少量 Newton-Schulz 迭代逼近极分解方向。

lecture05 会把这个 Newton-Schulz 迭代完整展开。

SOAP：在 Shampoo 的空间里使用 Adam 的尺度思想

SOAP 可以粗略理解成：先用 Shampoo 的矩阵结构找到更合适的基，再在那个基里做 Adam 风格的二阶矩缩放。



它对我们理解 Muon 的价值在于：Adam 和矩阵方法并不是两条完全断开的路。一个处理坐标尺度，一个处理矩阵空间。

方法	主要状态	核心几何
Adam	m_t, v_t	原始坐标轴上的对角缩放
Shampoo	L_t, R_t	矩阵左右空间预条件
SOAP	矩阵基 + Adam 状态	矩阵基中的自适应缩放

本讲你应该带走的四句话

1. 矩阵权重有行空间和列空间，不只是元素坐标。
2. Shampoo 用左右预条件矩阵缩放梯度。
3. 去掉累积的 Shampoo 会露出 $\text{Orth}(G) = U V^T$ 。
4. Muon 可以看成把 Momentum 的矩阵信号送进 Orth，再用 Newton-Schulz 近似实现。

$$G = U S V^T \rightarrow \text{Orth}(G) = U V^T$$

课后自检

- 能否解释左预条件和右预条件各自作用在哪里？
- 能否说清 $\text{Orth}(G)$ 保留了什么、丢掉了什么？

下一讲预告

我们正式定义 Muon：先得到动量矩阵 M_t ，再用 Newton-Schulz 把它正交化成 U_t 。