

Muon 核心：动量矩阵再做正交化

第五讲：Newton-Schulz、极分解与谱范数下降

Muon 的名字可以读成 MomentUm Orthogonalized by Newton-Schulz。它先形成矩阵动量，再把这个矩阵动量正交化，用谱更平坦的方向更新隐藏层权重。

本讲要回答

- Muon 的基本更新式是什么？
- $\text{Orth}(M) = UV^T$ 到底在做什么？
- Newton-Schulz 为什么能近似正交化？
- Muon 和 AdamW、Shampoo 的核心区别是什么？

本讲先不做

- 不展开所有 2026 年变体。
- 不把经验结论讲成定理。
- 不讲分布式系统细节，留到 lecture06。

这组讲义会固定符号： F 表示当前训练目标，训练时通常 $F = \hat{L}_N$ ； g_t 是 mini-batch 梯度， m_t 是一阶动量。

Muon 主要用于隐藏层的二维权重

设一个隐藏层权重为：

$$W_t \in \mathbb{R}^{m \times n}$$

第 t 步 mini-batch 梯度为：

$$G_t = \nabla_W F(W_t)$$

Muon 不通常用于所有参数。标量、向量、embedding 和输出头常用 AdamW 处理；Muon 主要用于隐藏层的二维矩阵参数。

Muon 组

线性层、MLP、attention 的隐藏层矩阵。

AdamW 组

bias、norm、embedding、输出头，以及不适合矩阵化的参数。

这件事很重要：Muon 在实践中通常是混合优化器，不是全模型所有参数都用 Muon。

Muon = Momentum + Orthogonalization

先形成矩阵动量。这里用归一化动量写法，代码中也常见未归一化写法，尺度可吸收到学习率里：

$$M_t = \mu M_{t-1} + (1 - \mu) G_t$$

然后对 M_t 做正交化近似：

$$U_t \approx \text{Orth}(M_t)$$

最后更新权重：

$$W_{t+1} = W_t - \eta_t U_t$$

梯度矩阵

G_t 来自 mini-batch。



动量矩阵

M_t 降低时间噪声。



正交更新

U_t 压平奇异值。

如果能做 SVD，Muon 的核心一行就很清楚

令动量矩阵的奇异值分解为：

$$M_t = U S V^T$$

理想正交化更新是：

$$\text{Orth}(M_t) = U V^T$$

这等价于把 S 里的奇异值全部替换成 1，只保留左右奇异向量。

方向信息

U 和 V 描述矩阵更新主要连接哪些输入/输出子空间。


幅值信息

S 描述各个奇异方向的强弱，Muon 会把它压平。

Muon 不是把每个元素变成 sign，而是把矩阵的奇异值谱变平。

低秩动量会让少数方向支配学习

在许多深度网络层里，梯度或动量矩阵可能接近低秩：少数奇异方向很大，许多方向很小。



压平奇异值后，小奇异方向不会被完全淹没。直觉上，Muon 给矩阵更新更多“方向覆盖”。

这是经验动机，不要误读成所有任务上的定理。严格说法是：Orth(M) 改变了矩阵更新的谱结构。

不用 SVD，怎样近似 Orth(M)?

Muon 使用 Newton-Schulz 类型的矩阵迭代。先归一化：

$$X_0 = M / (||M||_F + \varepsilon)$$

然后重复少量步骤：

$$A_k = X_k X_k^T$$

$$X_{k+1} = aX_k + (bA_k + cA_k^2)X_k$$

常见 Muon 实现使用调过的系数：

$$a = 3.4445, \quad b = -4.7750, \quad c = 2.0315$$

实现里通常会在矩阵较高时先转置，让矩阵乘法更便宜；结束后再转回来。

Newton-Schulz 在奇异值上做同一个函数

若 $X = U S V^T$ ，一次迭代会保持 U 、 V 不变，只改变奇异值：

$$s \rightarrow \varphi(s) = as + bs^3 + cs^5$$

重复 q 次就是把 φ 反复作用在每个奇异值上：

$$S \rightarrow \varphi^q(S)$$

设计系数的目标是让区间内的奇异值快速靠近 1，从而得到接近 $U V^T$ 的矩阵。

为什么快

只用矩阵乘法，适合 GPU；实践中常用少量步数。

为什么近似

小奇异值可能不完全到 1，因此正交化质量和步数、谱分布有关。

Muon 的高效来自这里：用低精度矩阵乘法近似本来要 SVD 才能精确得到的极分解方向。

实践里常把 Nesterov 思想放进 Muon

Muon 可以使用普通动量，也可以使用 Nesterov 风格的动量信号。直觉是先进已有动量看一眼，再计算新的梯度信号。

$$\text{lookahead: } W_t^{\text{look}} = W_t - \eta \mu M_{t-1}$$

$$G_t = \nabla F(W_t^{\text{look}}), \quad M_t = \mu M_{t-1} + (1 - \mu) G_t$$

然后仍然执行：

$$U_t \approx \text{Orth}(M_t), \quad W_{t+1} = W_t - \eta U_t$$

记住主线即可：Nesterov 改的是动量信号的形成方式，不改变“动量后正交化”这个核心结构。

Muon 的每个矩阵都应该形状一致

如果 $W_t \in \mathbb{R}^{m \times n}$, 那么:

对象	形状	含义
G_t	$m \times n$	当前 batch 的梯度矩阵
M_t	$m \times n$	动量矩阵
U_t	$m \times n$	正交化后的更新矩阵
W_{t+1}	$m \times n$	更新后的权重

若 $m \geq n$, 理想 U_t 满足 $U_t^T U_t \approx I$; 若 $m \leq n$, 则 $U_t U_t^T \approx I$ 。

这就是“半正交”：矩阵不一定方，但短边方向尽量正交。

AdamW 缩放坐标，Muon 整理奇异值

维度	AdamW	Muon
主要状态	m_t, v_t	M_t
缩放方式	逐坐标除以 $\sqrt{\hat{v}}$	把矩阵动量正交化
几何对象	坐标轴	矩阵奇异向量和奇异值
适用参数	几乎所有参数	主要是二维隐藏层权重

所以 Muon 不是 Adam 的简单替代品。实践中常常是 Muon 和 AdamW 混用。

hidden matrices → Muon, vectors/scalars/embeddings/head → AdamW

AdamW 是默认强基线；Muon 的价值在于对隐藏层矩阵更新做更结构化的处理。

Muon 更像轻量的瞬时矩阵几何

Shampoo 维护累积预条件器，Muon 只维护动量并正交化当前动量信号。

方法	核心状态	计算重点	直觉
Shampoo	L_t, R_t	矩阵逆根	长期估计左右空间曲率
Muon	M_t	Newton-Schulz 正交化	把当前动量方向谱压平
SOAP	矩阵基 + Adam 状态	基变换和二阶矩	矩阵空间里的 Adam 风格缩放

Muon 的吸引力在于它把矩阵几何压缩成一个相对简单、矩阵乘法友好的子程序。

如果 lecture04 是 “为什么 Orth 会出现”，本讲就是 “如何把 Orth 做得足够快”。

本讲你应该带走的四句话

1. Muon 先对二维隐藏层权重形成矩阵动量 M_t 。
2. 理想更新方向是 $\text{Orth}(M_t) = U V^T$ 。
3. Newton-Schulz 用少量矩阵乘法近似这个极分解方向。
4. Muon 改变的是矩阵奇异值结构，不是 Adam 式逐坐标二阶矩。

$$M_t \rightarrow \text{Orth}(M_t) \rightarrow W_{t+1} = W_t - \eta U_t$$

课后自检

- 能否说明 $\text{Orth}(M)$ 保留和丢掉了什么？
- 能否解释 Newton-Schulz 为什么只需矩阵乘法？

下一讲预告

我们会讲怎么真的用 Muon：参数分组、权重衰减、缩放、QKV、分布式成本和变体地图。